



UNIVERSITAT  
POLITÈCNICA  
DE VALÈNCIA

Escola Tècnica Superior d'Enginyeria Informàtica



# Tema 1. Introducción

Percepción (PER)

Curso 2019/2020

Departamento de Sistemas Informáticos y Computación

# Índice

- 1 Percepción ▷ 3
- 2 Teoría de la decisión estadística ▷ 7
- 3 Teoría de la decisión estadística en interacción ▷ 13
- 4 Aprendizaje en sistemas interactivos ▷ 17
- 5 Evaluación en sistemas interactivos ▷ 21

# Índice


- 1 *Percepción* ▷ 3
- 2 Teoría de la decisión estadística ▷ 7
- 3 Teoría de la decisión estadística en interacción ▷ 13
- 4 Aprendizaje en sistemas interactivos ▷ 17
- 5 Evaluación en sistemas interactivos ▷ 21

# Percepción

- *Percepción* como proceso cognitivo para captar información
- La percepción va estrechamente ligada al *Reconocimiento*
- Esta asignatura: *Percepción automática y Reconocimiento automático*
- Percepción automática como procesamiento informático de la información procedente de sensores
- La información es representada para su tratamiento informático posterior

# Adquisición, Representación y Reconocimiento


- Percepción engloba adquisición, representación y reconocimiento



- Sensor: cámara, micrófono, escáner, . . .
- Señal: fichero de imagen, audio, vídeo, texto, . . .
- Representación ( $x$ ): vector de características, cadena de símbolos, grafo, . . .

# Reconocimiento

- Reconocimiento como *clasificación*  $c(x) = c$  con  $c \in \{1, \dots, c, \dots, C\}$
- Reconocimiento como *secuencia de símbolos* (frase), i.e., reconocimiento de texto manuscrito:

  $\xrightarrow{\text{reconocimiento}}$  **may be consumed**

- En esta asignatura veremos reconocimiento como clasificación
- Clasificación desde la teoría de la decisión estadística

# Índice

- 1 Percepción ▷ 3
- 2 *Teoría de la decisión estadística* ▷ 7
- 3 Teoría de la decisión estadística en interacción ▷ 13
- 4 Aprendizaje en sistemas interactivos ▷ 17
- 5 Evaluación en sistemas interactivos ▷ 21

# Teoría de la decisión estadística

- La representación del objeto  $\mathbf{x}$  a clasificar es una *variable aleatoria*
- Clasificador de Bayes (clasificador de mínimo error):

$$\hat{c}(\mathbf{x}) = \underset{c=1\dots C}{\operatorname{argmax}} P(c \mid \mathbf{x}) = \underset{c=1\dots C}{\operatorname{argmax}} P(c) p(\mathbf{x} \mid c)$$

donde

$P(c)$  es la probabilidad a priori de la clase  $c$

$p(\mathbf{x} \mid c)$  es la distribución de probabilidad condicionada a la clase  $c$

- $p(\mathbf{x} \mid c)$  es una distribución de probabilidad sobre valores de  $x$  en la clase  $c$ 
  - Ej: Modelo de Markov oculto (SIN) u otra distribución (Gaussiana, . . . )
  - Se estima a partir de datos de la clase  $c$  (entrenamiento)



# Ejercicio: clasificador de Bayes

Se dispone de 1000 correos electrónicos etiquetados como *Spam* (100) y *NoSpam* (900). Asimismo, la palabra *Bingo* aparece en 40 correos de los etiquetados como Spam (S) y en 18 de los etiquetados como NoSpam (N).

Dado el siguiente correo:

"Get \$1000 Free - Try the New Slot Machines at Bingo Palace"

¿Cómo lo etiquetaríamos para minimizar la probabilidad de error?

## Ejercicio: clasificador de Bayes

Sea  $x = 1$  si la palabra *Bingo* está en el correo. El clasificador de Bayes sería:

$$\hat{c}(x) = \operatorname{argmax}_{c \in \{S, N\}} P(c \mid x = 1) = \operatorname{argmax}_{c \in \{S, N\}} P(c) p(x = 1 \mid c)$$

Estimamos empíricamente las distribuciones de probabilidad involucradas:

$$\begin{aligned} P(c = S) &= \frac{100}{1000} & P(c = N) &= \frac{900}{1000} \\ p(x = 1 \mid c = S) &= \frac{40}{100} & p(x = 1 \mid c = N) &= \frac{18}{900} \end{aligned}$$

Calculamos para cada clase:

$$\begin{aligned} P(c = S) p(x = 1 \mid c = S) &= \frac{100}{1000} \cdot \frac{40}{100} = 0.04 \\ P(c = N) p(x = 1 \mid c = N) &= \frac{900}{1000} \cdot \frac{18}{900} = 0.018 \end{aligned}$$


Por lo tanto,  $\hat{c}(x) = S$

# Algunas consideraciones

- La variable aleatoria  $x$  tendría que dar cuenta de la aparición o ausencia no sólo de la palabra *Bingo*, sino de todas las palabras del vocabulario
- De esta forma,  $x$  podría ser un vector donde cada componente del mismo estuviera asociado a una palabra distinta (Tema 2)
- Este tipo de representación conlleva una alta dimensionalidad que puede ser interesante reducir (Temas 3 y 6)
- Estos objetos pueden compararse por distancias (Tema 4)
- Existe probabilidades condicionales  $p(x | c)$  bien conocidas más allá de la aparición o ausencia de un objeto (palabra) en particular (Tema 5)
- Los objetos de cada clase pueden no ser linealmente separables y podría convenir que lo fueran (Tema 6)
- Podemos usar más de un clasificador y combinarlos (Tema 7)

# Clasificación con entrenamiento off-line

- Muestras de entrenamiento etiquetadas  $\{(x_1, c_1), \dots, (x_n, c_n)\}$
- Estimación de modelo  $M$  ( $P(c)$  y  $p(\mathbf{x} | c)$ ) a partir de entrenamiento
- Clasificación de  $x$  de acuerdo a modelo  $M$



- En esta asignatura solo estudiaremos el entrenamiento off-line

# Índice

- 1 Percepción ▷ 3
- 2 Teoría de la decisión estadística ▷ 7
- 3 *Teoría de la decisión estadística en interacción* ▷ 13
- 4 Aprendizaje en sistemas interactivos ▷ 17
- 5 Evaluación en sistemas interactivos ▷ 21


# Teoría de la decisión estadística en interacción

Motivación:

- Sistema de reconocimiento (clasificación) puede cometer errores
  - Clasificación de textos, traducción automática, reconocimiento del habla
- Es necesaria la supervisión (interacción) de un usuario (humano)
- Existe supervisión humana en
  - Desarrollo: anotación de los datos empleados en estimar los modelos
  - Producción: corrección de posibles errores
  - Realimentación: considerar las correcciones para mejorar el sistema
- Es necesario adaptar la teoría de la decisión en presencia de interacción

# Clasificación con realimentación sin reentrenamiento

- El usuario realiza una corrección  $f$  sobre la clasificación del sistema  $\hat{c}(x)$

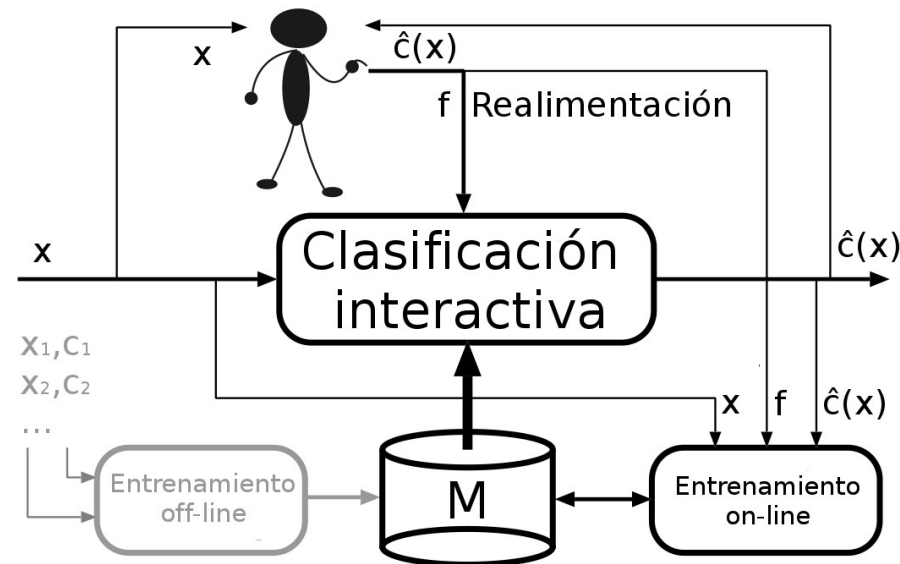


$$\hat{c}(x) = \operatorname{argmax}_{c=1 \dots C} P(c \mid x, f)$$

- El modelo  $M$  no se modifica, pero el sistema emplea la realimentación  $f$
- Una posible realimentación es solicitar una clasificación alternativa de  $x$

# Clasificación con realimentación con reentrenamiento

- La realimentación proporciona nuevas muestras de entrenamiento etiquetadas
- Es posible reentrenar el modelo  $M$  para incorporar las nuevas muestras



- ¿Cómo contribuyen las nuevas muestras al modelo existente  $M$  en un sistema interactivo?



# Índice

- 1 Percepción ▷ 3
- 2 Teoría de la decisión estadística ▷ 7
- 3 Teoría de la decisión estadística en interacción ▷ 13
- 4 *Aprendizaje en sistemas interactivos* ▷ 17
- 5 Evaluación en sistemas interactivos ▷ 21

# Aprendizaje en sistemas interactivos

Algunas estrategias de entrenamiento en sistemas interactivos son:

- On-line learning
- Active learning

# On-line learning

- Muestras de entrenamiento iniciales  $T = \{(x_1, c_1), \dots, (x_n, c_n)\}$
- La realimentación del usuario genera un nuevo conjunto de entrenamiento  $T' = \{(x_{n+1}, c_{n+1}), \dots, (x_m, c_m)\}$
- El nuevo modelo  $M'$  se obtiene de la combinación de  $T$  y  $T'$ , empleando  $T'$  para actualizar sus parámetros (“probabilidades”)
- Se debe ponderar la contribución entre  $T$  y  $T'$  a  $M'$  mediante interpolación

# Active learning

- Se dispone de:
  - Conjunto reducido de muestras etiquetadas  $T = \{(x_1, c_1), \dots, (x_n, c_n)\}$
  - Conjunto amplio de muestras no etiquetadas  $U = \{(x_{n+1}, ?), \dots, (x_m, ?)\}$
- El etiquetado de muestras no etiquetadas es costoso
- El sistema elige  $T' \subset U$  del menor tamaño posible para etiquetar por el usuario
- El error del modelo entrenado con  $T \cup T'$  debe ser menor que con  $T$
- Algunos criterios de selección de muestras a etiquetar:
  - *Uncertainty sampling*: muestras cuyo etiquetado es más incierto
  - *Expected model change*: muestras que mayor cambio causan en el modelo

# Índice

- 1 Percepción ▷ 3
- 2 Teoría de la decisión estadística ▷ 7
- 3 Teoría de la decisión estadística en interacción ▷ 13
- 4 Aprendizaje en sistemas interactivos ▷ 17
- 5 *Evaluación en sistemas interactivos* ▷ 21

# Evaluación en sistemas interactivos

- La evaluación convencional basada en tasa de error no es apropiada
- La evaluación se basa en *esfuerzo* o *productividad* del usuario:
  - Esfuerzo: errores corregidos (interacciones requeridas)
  - Productividad: en términos de tiempo requerido para realizar una tarea
- La **evaluación automática** de un sistema interactivo se basa en **esfuerzo**
  - Modelo de usuario en base a un conjunto de interacciones (operaciones)
  - Es una aproximación a la función objetivo a maximizar (productividad)
  - Es posible evaluar y comparar sistemas interactivos inmediatamente
- La **evaluación manual** de un sistema interactivo se basa en **productividad**
  - Corresponde con la percepción del usuario de la utilidad del sistema
  - Es costosa: reclutar usuarios, organización, control de experimentos, etc.
  - Número de sistemas a evaluar limitado, resultados no inmediatos